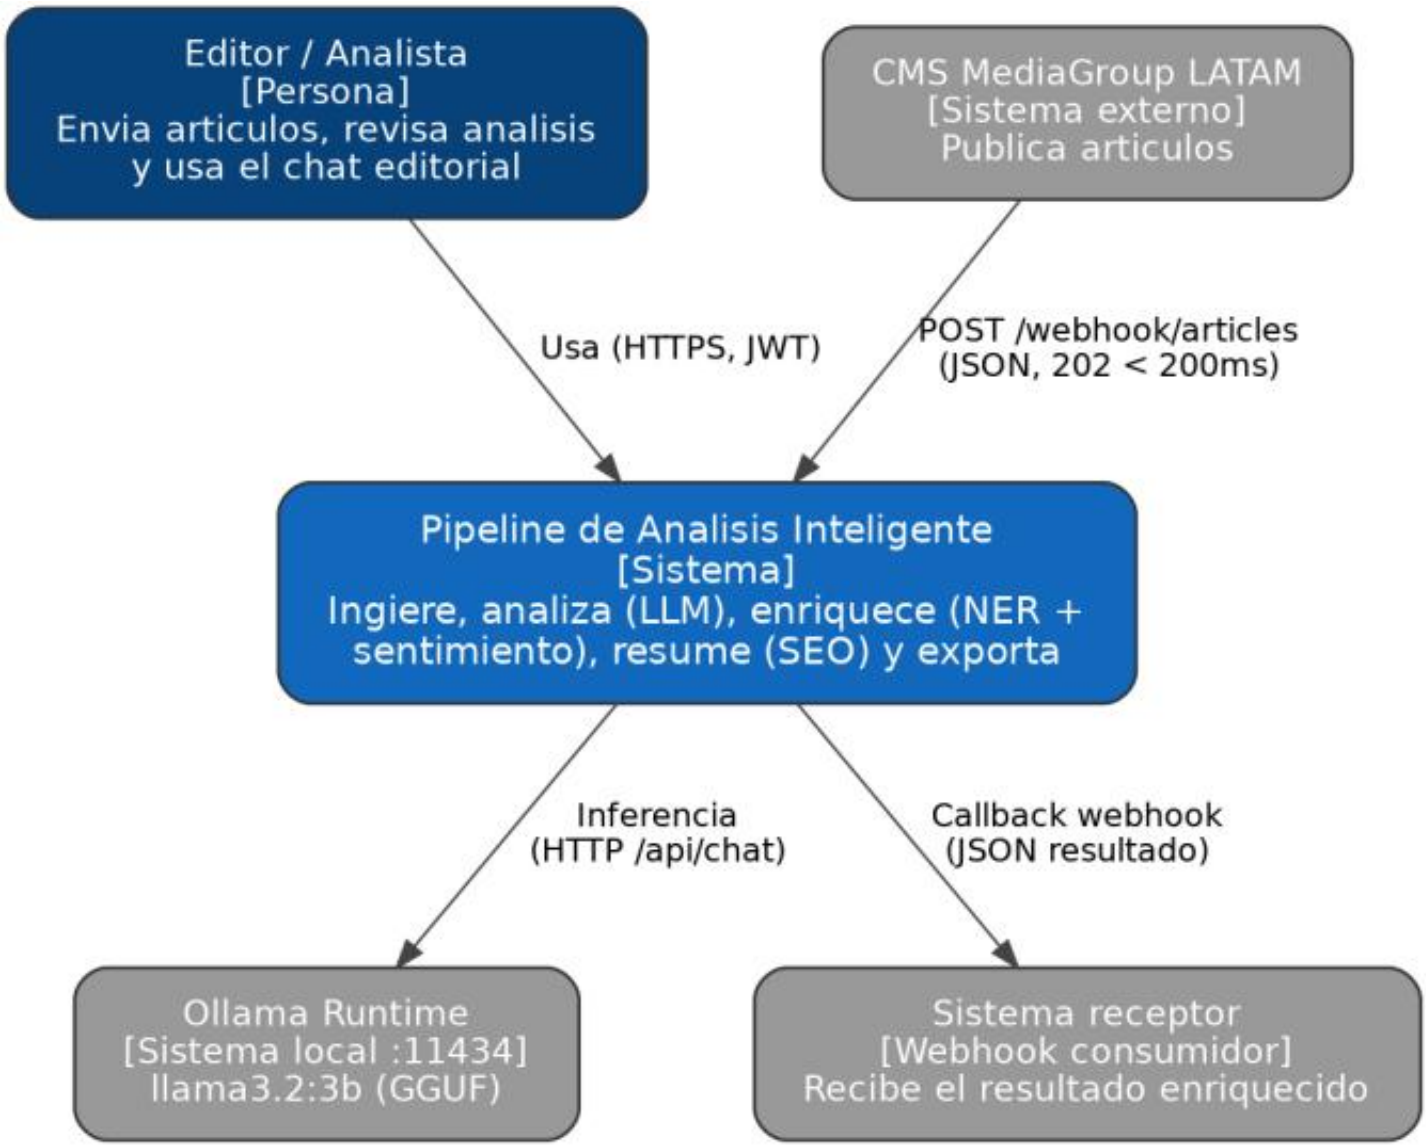
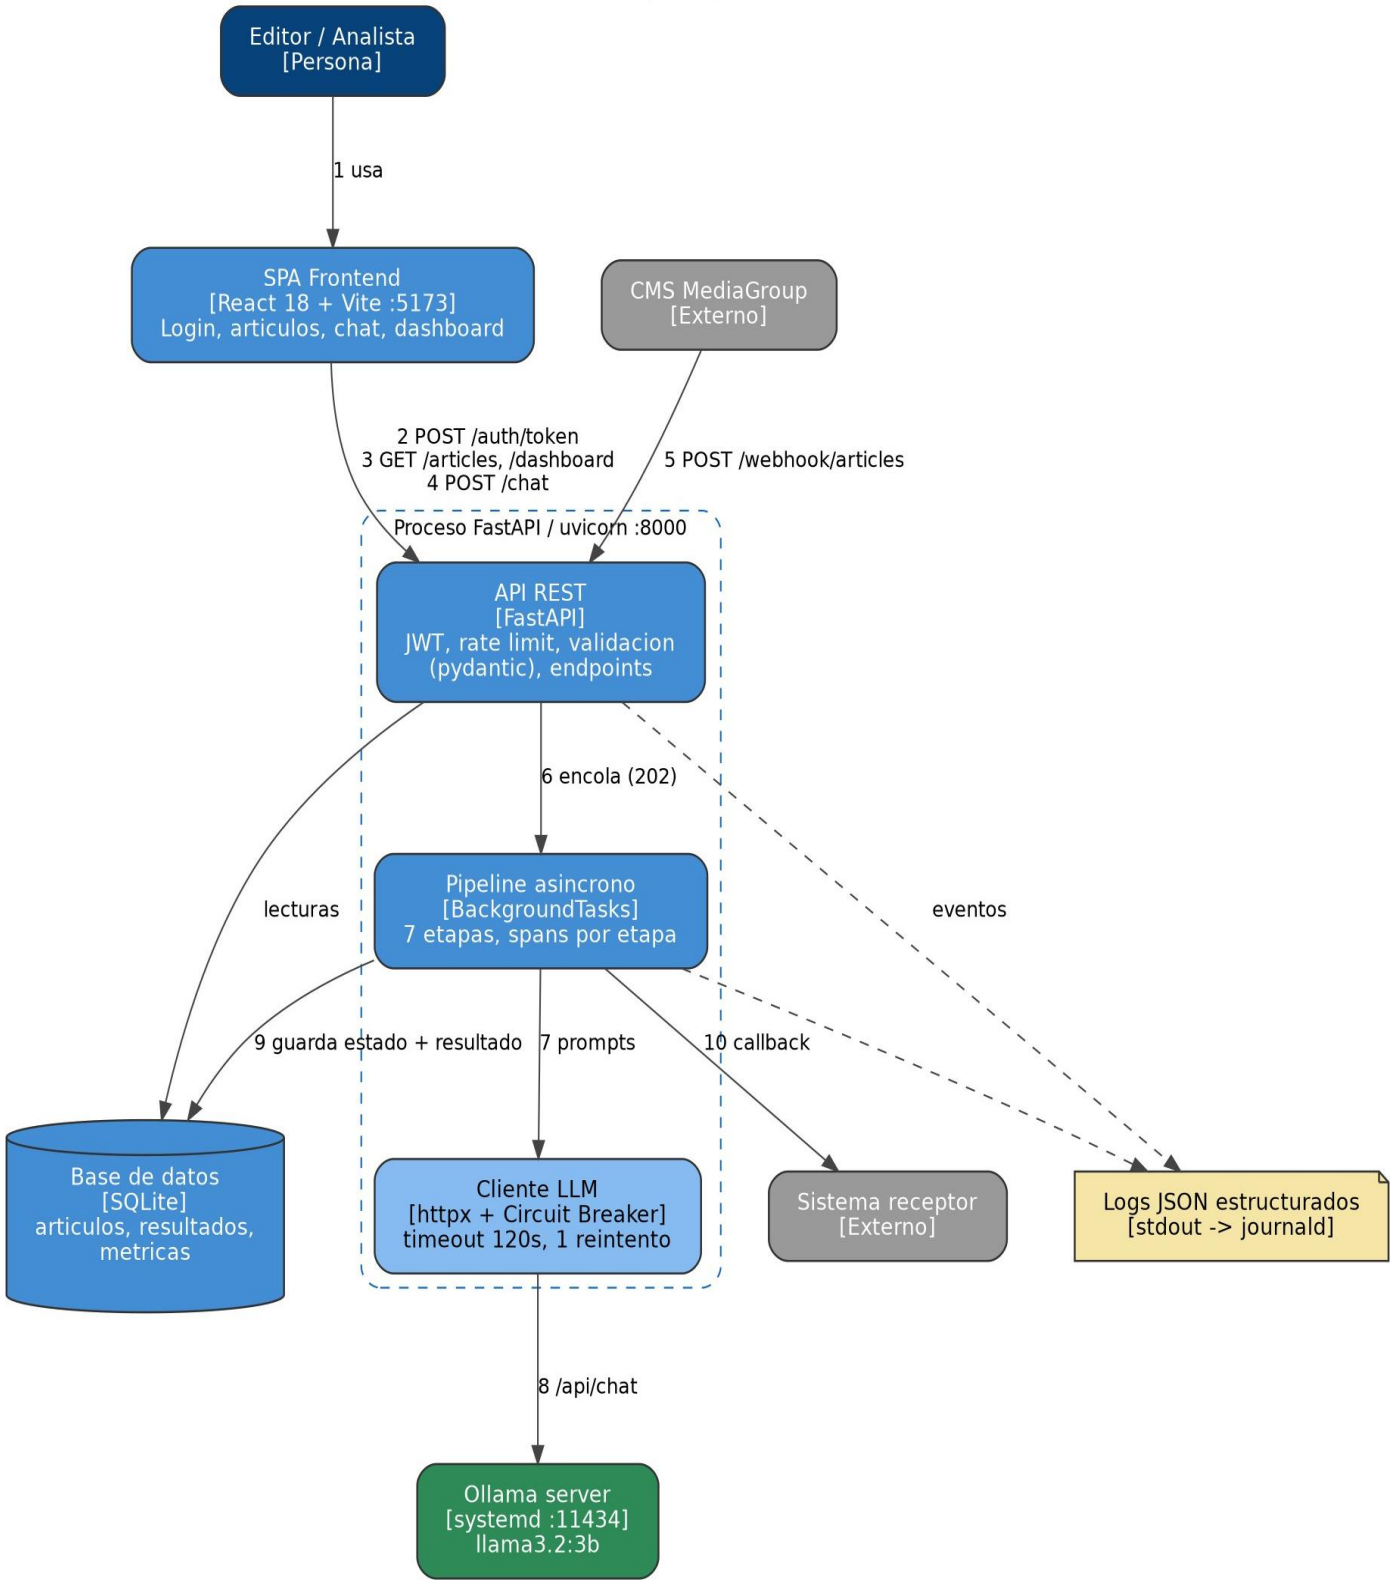
Diagrama C4

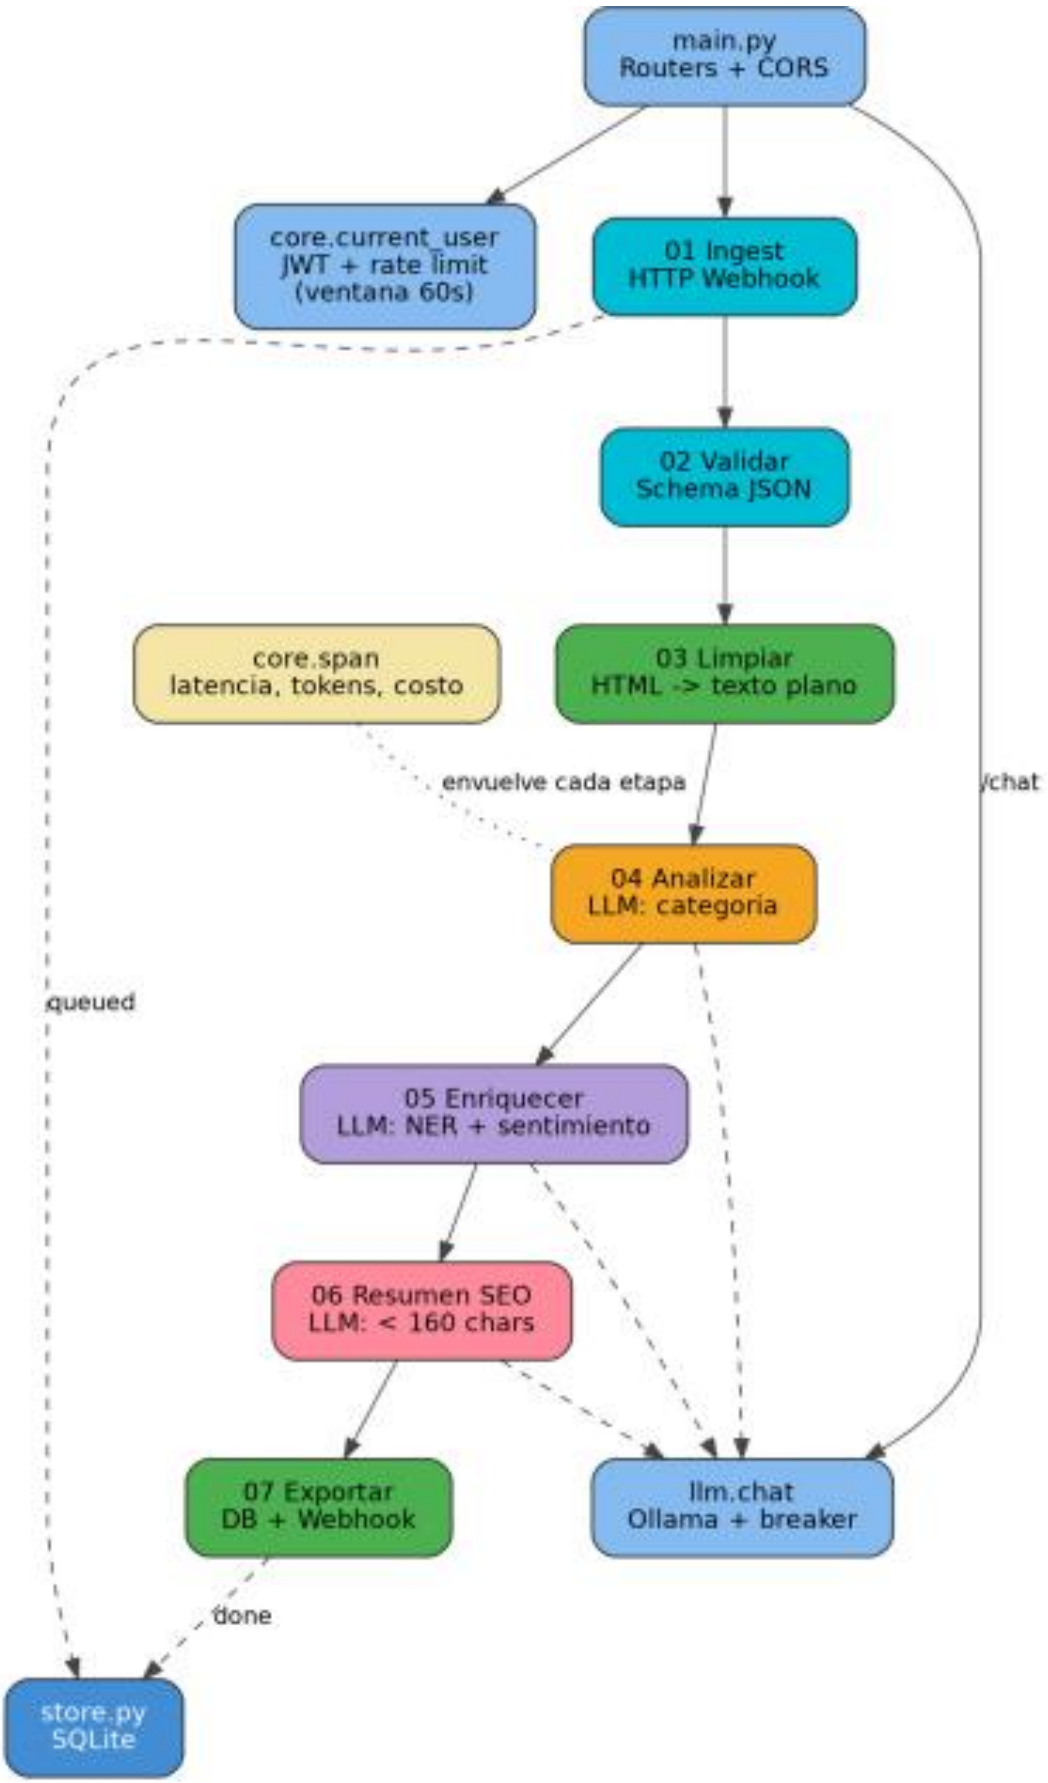
Nivel 1 – Contexto del sistema



Nivel 2- Contenedores y flojo de datos



Nivel 3- componente: API + pipeine



Nivel 4 - decisión de diseño y evolución futura

Decision	Alternativa descartada	Justificacion	Riesgo / mitigacion
FastAPI BackgroundTasks	Celery + Redis / cola gestionada	Equipo de 2-3 personas; cero infraestructura extra; cumple 202 en < 200 ms.	Se pierden tareas en un reinicio. Mitigacion: estado queued en DB; reencolado manual (mejora futura).
SQLite	PostgreSQL	Un solo archivo, sin servicio que operar; suficiente para el volumen del curso.	Escritura concurrente limitada. Migrable a Postgres cambiando store.py.
Ollama llama3.2:3b local	Vertex AI como primario	Privacidad editorial, costo variable ~0, funciona offline.	Menor calidad y mayor latencia en CPU. Se documenta en la comparativa vs API cloud.
3 llamadas LLM acotadas (categoria / NER+sentimiento / SEO)	1 prompt gigante	Un modelo 3b falla menos con tareas pequenas y salida JSON corta.	Mas llamadas = mas latencia. Se mide por etapa con spans.
JSON mode + parseo tolerante + validacion de enums	Confiar en la salida cruda	El modelo puede devolver JSON invalido o valores fuera del catalogo.	Categoria cae a 'otros', sentimiento a 'neutral'; resumen SEO truncado duro a < 160.
Circuit breaker + 1 reintento + timeout 120 s	Reintentos infinitos	Evita saturar un Ollama caido y liberar el pipeline rapido.	Falsos positivos en modelo frio. Umbral 3 fallos, reset 30 s.
Span por etapa (latencia, tokens, costo)	Solo logs de error	Observabilidad total pedida en el enunciado; alimenta dashboard y E6.	Costo local es estimado (energia + hardware), no facturado.
JWT HS256 + rate limit en memoria	OAuth / API gateway	Suficiente para un servicio unico; simple de auditar.	Rate limit no se comparte entre instancias. Escalar requeriria Redis.