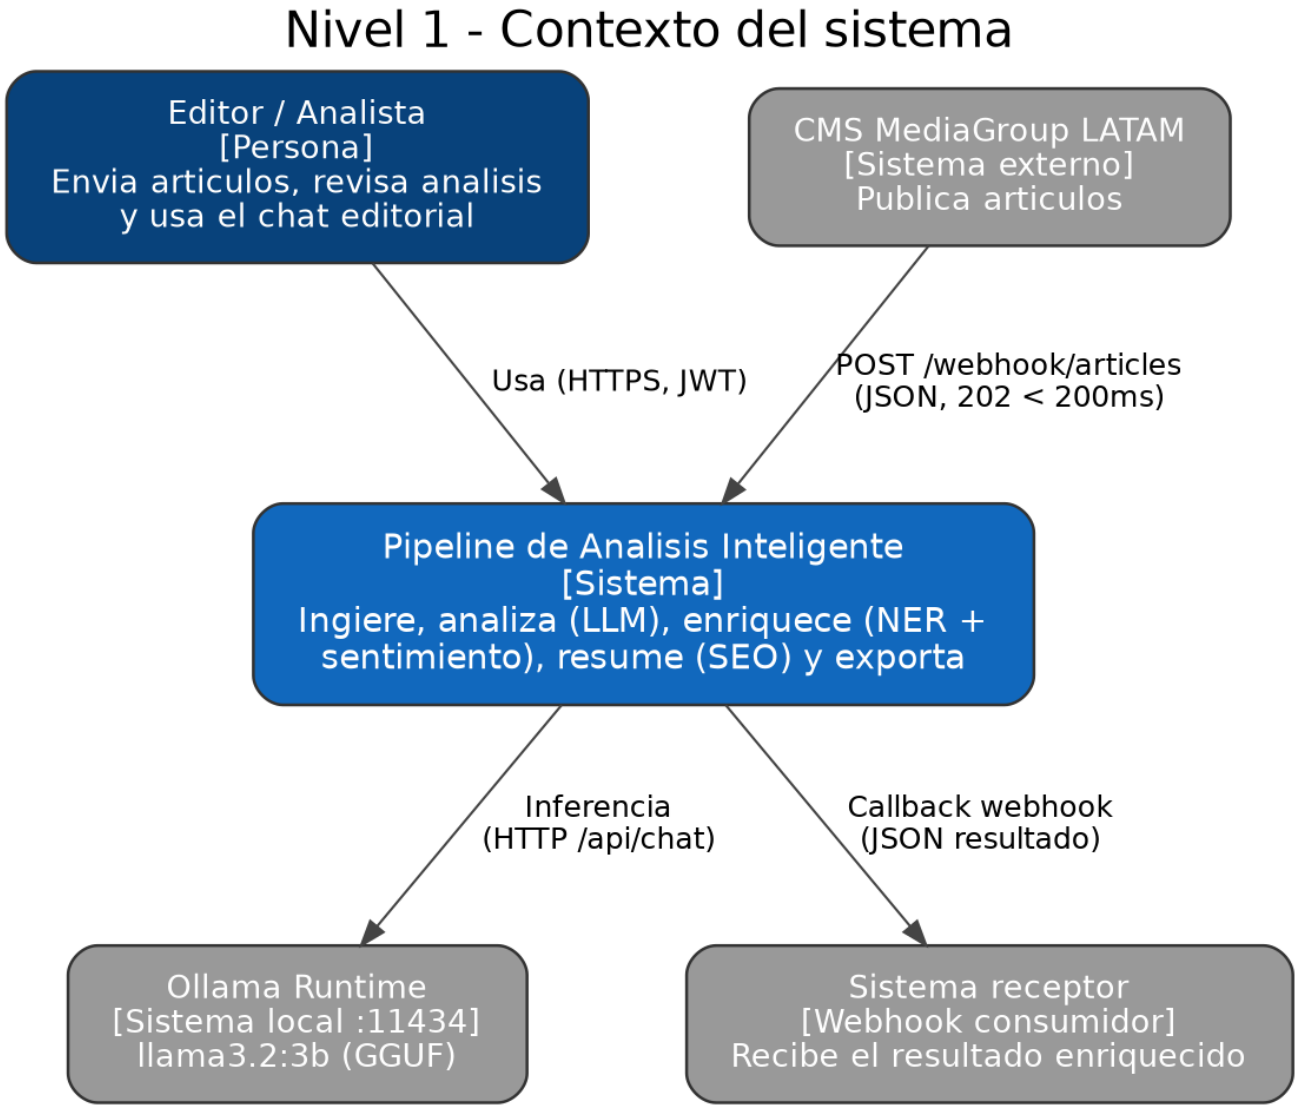
E1 - Diagrama de Arquitectura (C4)

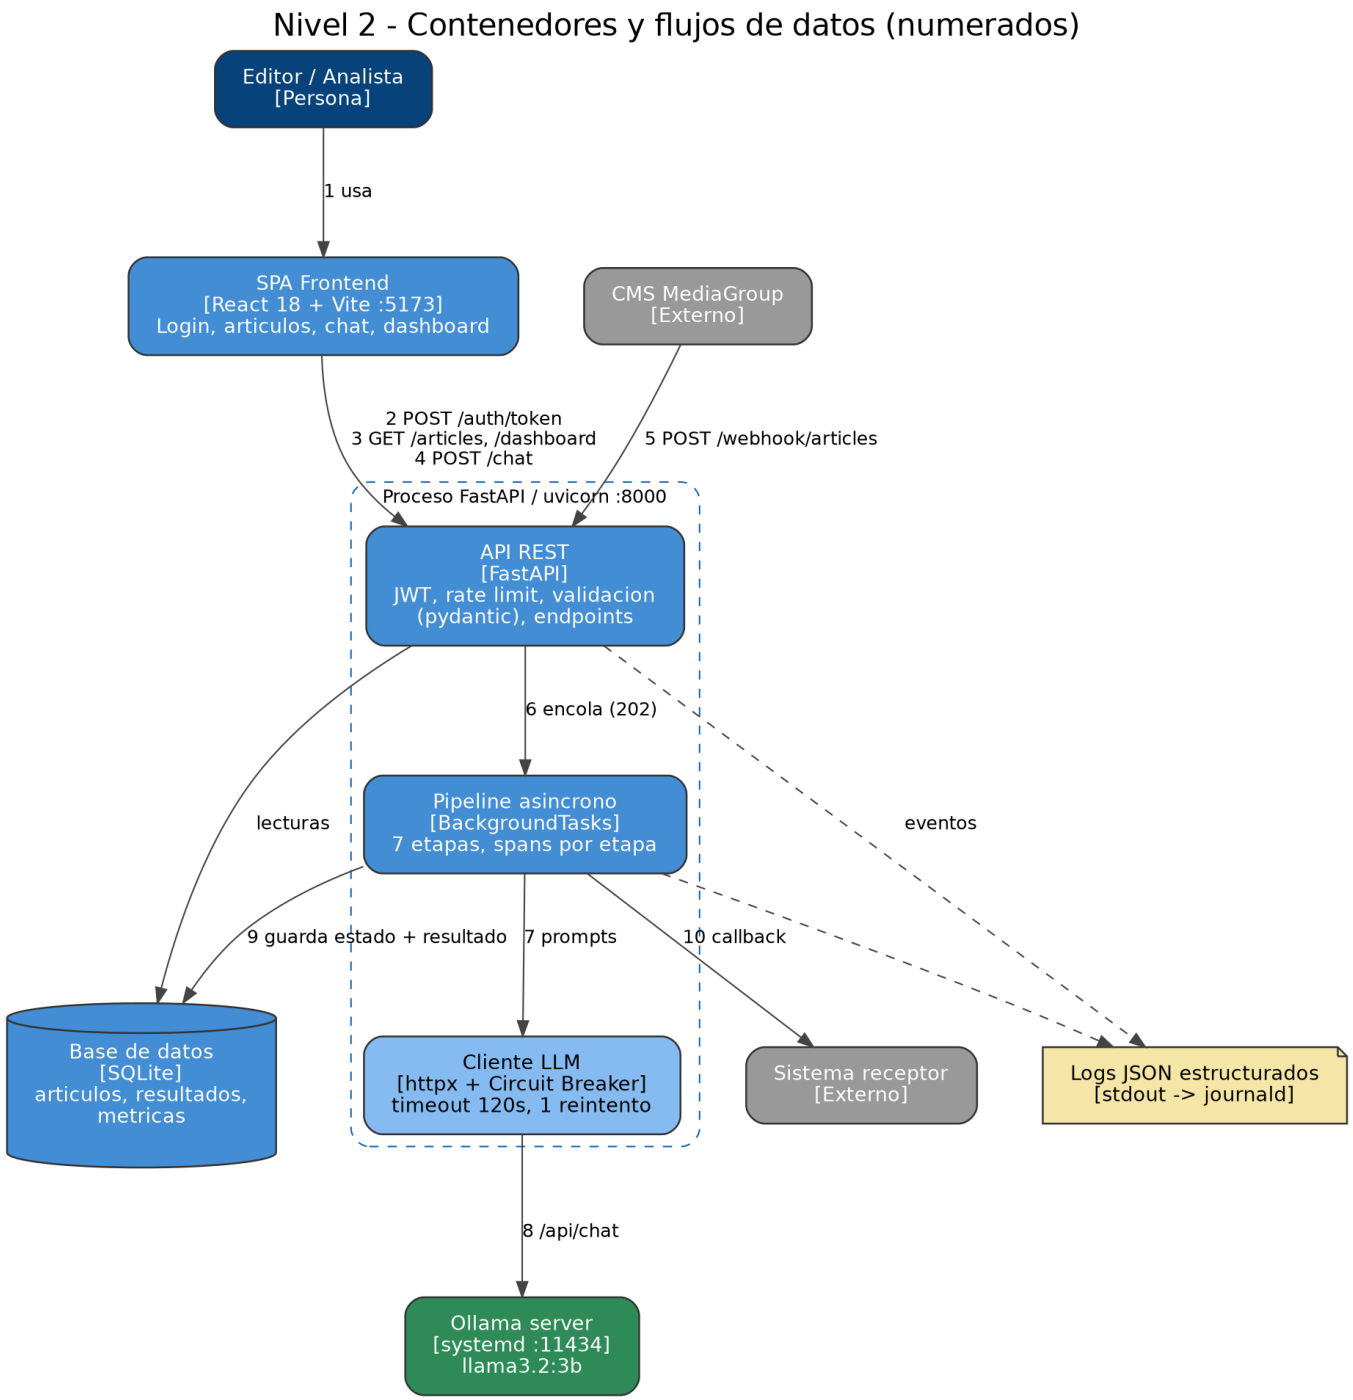
Nivel 1: contexto. Que es el sistema y con quien interactua.



Leyenda: azul oscuro = persona | azul = sistema propio | gris = sistema externo.
Decision clave: el CMS NO espera el analisis; recibe 202 en < 200 ms y el resultado llega por callback.
Decision clave: la inferencia es 100% local (Ollama): sin datos editoriales a terceros y costo marginal por token ~0.

E1 - Diagrama de Arquitectura (C4)

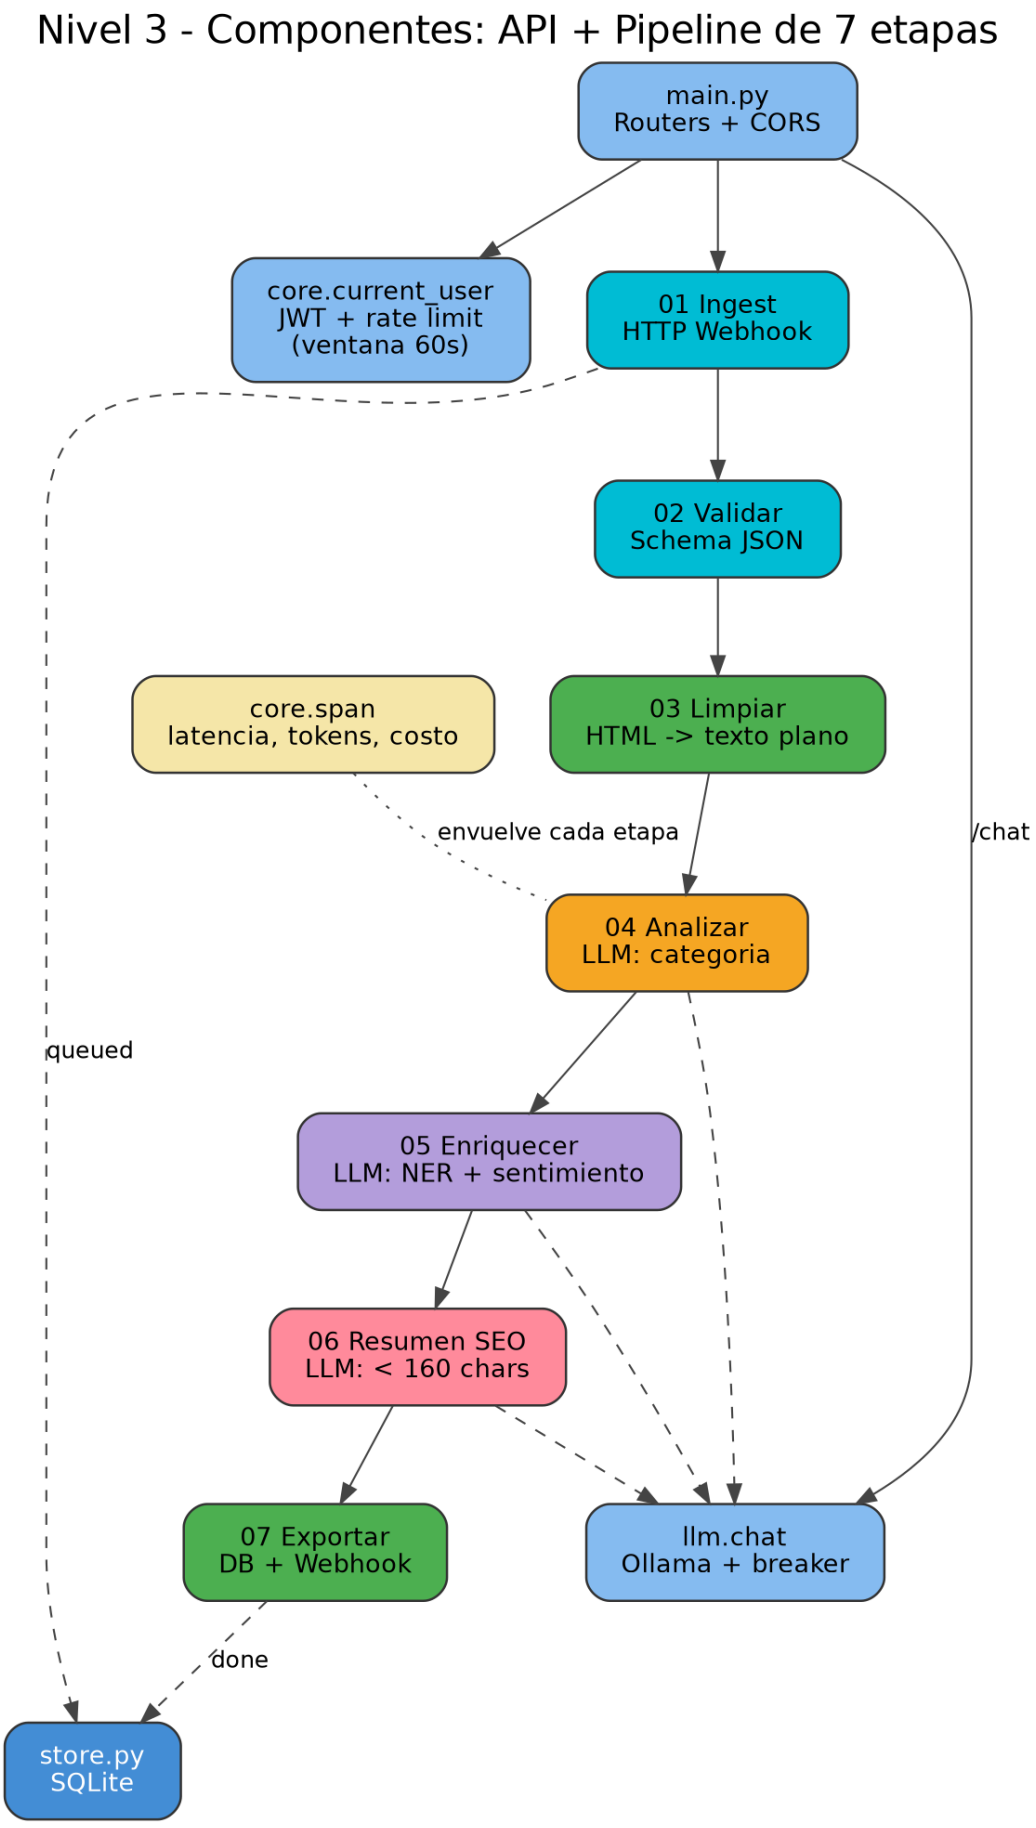
Nivel 2: contenedores y flujos de datos. Los numeros indican el orden del flujo.



Flujo principal: 5 -> 6 -> 7 -> 8 -> 9 -> 10. Flujo de consulta: 2 -> 3. Flujo de chat: 4 -> 8. Todo evento se registra como JSON.

E1 - Diagrama de Arquitectura (C4)

Nivel 3: componentes del backend y las 7 etapas del pipeline.



E1 - Decisiones de diseno y trade-offs

Cada decision con la alternativa descartada y su riesgo asumido.

Decision	Alternativa descartada	Justificacion	Riesgo / mitigacion
FastAPI BackgroundTasks	Celery + Redis / cola gestionada	Equipo de 2-3 personas; cero infraestructura extra; cumple 202 en < 200 ms.	Se pierden tareas en un reinicio. Mitigacion: estado queued en DB; reencolado manual (mejora futura).
SQLite	PostgreSQL	Un solo archivo, sin servicio que operar; suficiente para el volumen del curso.	Escritura concurrente limitada. Migrable a Postgres cambiando store.py.
Ollama llama3.2:3b local	Vertex AI como primario	Privacidad editorial, costo variable ~0, funciona offline.	Menor calidad y mayor latencia en CPU. Se documenta en la comparativa vs API cloud.
3 llamadas LLM acotadas (categoria / NER+sentimiento / SEO)	1 prompt gigante	Un modelo 3b falla menos con tareas pequenas y salida JSON corta.	Mas llamadas = mas latencia. Se mide por etapa con spans.
JSON mode + parseo tolerante + validacion de enums	Confiar en la salida cruda	El modelo puede devolver JSON invalido o valores fuera del catalogo.	Categoria cae a 'otros', sentimiento a 'neutral'; resumen SEO truncado duro a < 160.
Circuit breaker + 1 reintento + timeout 120 s	Reintentos infinitos	Evita saturar un Ollama caido y liberar el pipeline rapido.	Falsos positivos en modelo frio. Umbral 3 fallos, reset 30 s.
Span por etapa (latencia, tokens, costo)	Solo logs de error	Observabilidad total pedida en el enunciado; alimenta dashboard y E6.	Costo local es estimado (energia + hardware), no facturado.
JWT HS256 + rate limit en memoria	OAuth / API gateway	Suficiente para un servicio unico; simple de auditar.	Rate limit no se comparte entre instancias. Escalar requeriria Redis.