Reflexión crítica

Proyecto B: Pipeline de Análisis Inteligente (Ollama local)

Autor: Sofia Ximena Castro Rodríguez · 25 de octubre de 2026

Construí un pipeline asíncrono de siete etapas para analizar artículos periodísticos (categoría, entidades, sentimiento y resumen SEO). Usa una API FastAPI, una interfaz en React y un modelo llama3.2:3b que corre localmente con Ollama. En este documento explico qué funcionó, qué cambiaría y qué aprendí que no estaba en el contenido del curso.

1. Qué funcionó

- **Autenticación con JWT.** El login entrega un token firmado con expiración, y todos los endpoints de negocio exigen ese token: sin él, la API responde 401. El frontend lo guarda y lo envía en cada petición, y si el token expira cierra la sesión automáticamente.
- **Conexión local con Ollama.** El backend se comunica con el modelo por HTTP en localhost, sin enviar el texto de los artículos a terceros y sin costo por token. Esa privacidad y esa independencia de un proveedor eran el motivo principal.
- **Comunicación entre el frontend y el backend.** La interfaz en React consume la API REST: inicio de sesión, envío de artículos, chat y dashboard. Como el análisis corre en segundo plano, la interfaz consulta el estado cada pocos segundos y muestra cómo cada artículo pasa de en cola a procesando y a terminado.
- **Rate limiting.** Cada usuario tiene un límite de solicitudes por minuto, más estricto en el chat porque cada mensaje consume inferencia. Al superarlo, la API responde 429 e indica cuándo reintentar.
- **Circuit breaker.** Si Ollama falla varias veces seguidas, el sistema deja de llamarlo durante unos segundos y responde rápido con un error claro, en lugar de acumular peticiones colgadas. Después prueba de nuevo y se recupera solo.

En conjunto, estas piezas protegen el sistema en tres frentes: quién puede entrar, cuánto puede usar y qué pasa cuando una dependencia falla.

2. Qué cambiaría

- **Reporte descargable para el CEO.** Agregaría el reporte ejecutivo que se pueda descargar desde el dashboard, en PDF. Resumiría el periodo con indicadores que el sistema ya calcula: artículos procesados, distribución por categoría y sentimiento, entidades más mencionadas, latencia, costo estimado y errores. Lo expondría como un endpoint protegido con JWT y un botón de descarga en la interfaz, para que la información llegue a quien decide sin que tenga que leer logs ni usar la API.
- **Cola durable para el procesamiento.** Hoy las tareas en segundo plano se pierden si el servidor se reinicia. Con una cola persistente, ningún artículo en proceso se perdería.
- **Medir la calidad del modelo.** Solo probé con cinco artículos de muestra, que sirven como prueba de humo y no como evaluación. Armaría un conjunto de 30 a 50 artículos etiquetados para medir qué tan bien un modelo de 3B clasifica y extrae entidades.
- **Respaldo en la nube y usuarios reales.** Implementaría el fallback a un modelo en la nube cuando Ollama falle, y reemplazaría el usuario único por usuarios guardados en base de datos con contraseñas cifradas.

3. Qué aprendí que no estaba en el curso

- **React aplicado a un proyecto real.** No había usado React antes. Aprendí a organizar la interfaz en componentes, manejar el estado con hooks, consumir una API desde el navegador, actualizar la pantalla de forma periódica y controlar la sesión del usuario.
- **JWT en desarrollo, no solo en teoría.** Aunque el curso explicó qué es un JWT, no sabía cómo aplicarlo al construir una aplicación. Aprendí a firmar y verificar el token en el backend, a darle expiración, a guardarlo en el cliente y enviarlo en el encabezado de cada petición, y a manejar los casos de token inválido o vencido. También entendí que el secreto de firma es crítico: no debe quedarse con el valor de ejemplo.

4. Conclusión

El proyecto me mostró que construir un sistema con LLM va mucho más allá de llamar a un modelo: la seguridad, los límites de uso y la resiliencia son lo que lo vuelve utilizable. Si lo repitiera, mediría la calidad del modelo desde el inicio y entregaría desde la primera versión un reporte que el CEO pueda abrir y entender.